Hive 入门

周维萍

2013年4月

一.Hive 简介

Hive 是基于 hadoop 分布式文件系统的一种数据库,它的数据都是以文件文件形式存在的。 Hive 中的每一条记录对应于文件中的一行,各个字段的值是被指定的分隔符分隔的。在读数据的时候,会将文件行以分隔符分隔字段值,并将各个值按顺序给字段;现有的 hive 的权限基于文件的,如果某个用户对表对应的文件有读的权限,那么用户就对表有读的权限。

当前 hive 运用最多的是分区, hive 会将各个分区的数据分别放在不同的文件夹下;

在用 hive 执行 SQL 语句时,是将语句处理成 mapreduce 程序运行的。

二.数据类型

```
整型
int
          4字节
smallint 2字节
Tinyint 1字节
bigint 8字节
浮点数
float
double
字符串
string
布尔型
boolean
不支持日期时间型
不支持二进制串
其它数据类型
ARRAY
MAP
STRUCT
 CREATE TABLE complex (
coll ARRAY<INT>,
   col2 MAP<STRING, INT>,
col3 STRUCT<a:STRING, b:INT, c:DOUBLE>
hive> SELECT col1[0], col2['b'], col3.c FROM complex; 1 2 1.0
```

三.支持各种内建函数

详见 hive 函数大全.pdf

四.DDL(数据定义)

1. 创建和删除建数据库

```
create database if not exists db_test
comment '用于测试';
drop database if exists db_test;
```

2. 建表

```
create external table order_joined_extend(
  addr_id bigint comment 'address id' ,
  alliance_id int ,
  allot_quantity int ,
  city_ship_type_desc string
)
  comment 'order_joined_extend'
  partitioned by (create_date string, type string)
  row format delimited fields terminated by '\001'
  lines terminated by '\n'
  stored as textfile
  location '/home/zhouweiping/order_joined_extend/';
```

external 建立外部表。外部表的好处: a.可以直接将数据文件放到 location 指定的目录, 在 hive 中即可查询出数据; b.可以多个表使用一份数据, 只需将 location 指向同一个目录;

partitioned by 建立分区表。分区表是将分区列值一样的放到一个文件中,如果该分区列下还有子分区,会在该文件夹下再分小文件夹;如图:

```
[zhouweiping@h252021 ~]$ hdfs ls /share/comm/ddclick/ | head -3
Found 239 items
drwxrwxr-x
                - maze
- maze
                                                          0 2013-02-01 10:24 /share/comm/ddclick/2012-08-30
                             supergroup
drwxrwxr-x
                              supergroup
                                                          0 2013-01-21 21:17 /share/comm/ddclick/2012-09-01
[zhouweiping@h252021 ~]$ hdfs ls /share/comm/ddclick/2012-09-01 | head -3
Found 39 items
                                                       0 2013-01-21 20:05 /share/comm/ddclick/2012-09-01/ddclick_account 0 2013-01-21 19:38 /share/comm/ddclick/2012-09-01/ddclick_bang
drwxrwxr-x
                 - maze supergroup
drwxrwxr-x
                    maze supergroup
[zhouweiping@h252021 ~]$ hdfs ls /share/comm/ddclick/2012-09-01/ddclick_bang
Found 12 items
                                             0 2013-01-21 19:38 /share/comm/ddclick/2012-09-01/ddclick_bang/_SUCCESS
0 2013-01-21 19:34 /share/comm/ddclick/2012-09-01/ddclick_bang/_logs
22286078 2013-01-21 19:35 /share/comm/ddclick/2012-09-01/ddclick_bang/part-m-00000
drwxrwxr-x
                 - maze supergroup
                 3 maze supergroup
-rw-rw-r--
                                             21978171 2013-01-21 19:35 /share/comm/ddclick/2012-09-01/ddclick_bang/part-m-00001 22185937 2013-01-21 19:35 /share/comm/ddclick/2012-09-01/ddclick_bang/part-m-00002 22392740 2013-01-21 19:35 /share/comm/ddclick/2012-09-01/ddclick_bang/part-m-00003
-rw-rw-r--
                 3 maze supergroup
-rw-rw-r--
                 3 maze supergroup
                 3 maze supergroup
-rw-rw-r--
                3 maze supergroup
                                             22196028 2013-01-21 19:35 /share/comm/ddclick/2012-09-01/ddclick bang/part-m-00004
```

row format 指定表中行列分隔符。

Stored as 文件存储的格式,此处的 textfile。

Location 指定表中数据文件存放的 hdfs 目录。该参数默认为: /user/hive/warehouse/dbname.db/tablename

也可以用create table table_name like old_table_name,但是这个只能建内表,不能建外表,就是加了external,所建的表任然是内表;而且在建表时如果原表是分区表,新建的表也只是一般的表,原表中的分区字段成了新表中的一般字段

3. 建表的时候可以同时插入数据

```
create table order_joined_extend1
comment 'order_joined_extend'
row format delimited fields terminated by '\001'
lines terminated by '\n'
stored as textfile
location '/home/zhouweiping/order_joined_extend1/'
as
select * from order_joined_extend;
```

但是这种方法不支持外部表和分区表,并且在建表时不能指定详细的列

4. 删除表

drop table if exists order joined extendl;

删除的表可能是外部表或者内表,在删除外部表时只是删除了表结构,数据文件依然存在

5. 修改表

```
增加删除分区
alter table order_joined_extend
add partition(create_date='2012-09-01', type='ddclick_bang')
location '/share/comm/ddclick/2012-09-01/ddclick_bang/';
alter table order_joined_extend
drop if exists partition(create_date='2012-09-01', type='ddclick_bang');
```

```
重命名
```

alter table order_joined_extend rename to order_joined_extend_rename;

```
替换原有的列,替换时只是在分区列之前,分区列不变
ALTER TABLE order_joined_extend REPLACE COLUMNS
(
product_id string,
```

```
product_name string,
bd_name string
)
```

```
增加列,之后在分区之前的最后一列加,不能指定到某列之后
alter table order_joined_extend
add columns (add_col_test string)
```

```
内部表转外部表
alter table tablePartition set TBLPROPERTIES ('EXTERNAL'='TRUE');
外部表转内部表
alter table tablePartition set TBLPROPERTIES ('EXTERNAL'='FALSE');
```

6. Show/describle

```
show databases;
show tables;
show tables '*tianzhao*';
显示表中中含有tianzhao的表名

show partitions table_name;
展示表中现有的分区

desc formatted table_name;
可以描述出很多信息,包括字段,location,分区字段,是内表或者外表等;

show functions;
显示可以用的函数列表,包括可用的udf函数。

describe function length;
返回length函数的说明

show table extended like order_joined_extend partition(create_date='2012-09-01', type='ddclick_bang');
显示指定分区的一些信息
```

五.DML(数据操作)

Hive 只支持 select、insert,不支持 delete、update

1. load 数据

Load本地数据到hive,最好指定本地文件的绝对路径 追加导入数据: load data local inpath '/home/zhouweiping/d.dat' into table order joined extend1;

覆盖导入数据: load data local inpath '/home/zhouweiping/d.dat' **overwrite** into table order_joined_extend1;

加载hdfs上的数据到hive表

如果是外表可以直接将数据文件拷贝到location的目录

Hadoop fs - cp from location

内表或者外表都可以用1oad的方法

load data inpath '/home/zhouweiping/d.dat' into table order_joined_extendl;

load 数据时:

如果数据在本地,会将本地数据复制一份到 hdfs 中表的 location;

如果是 hdfs 是的数据,会直接移动到 location; 所以如果 load 数据的数据文件跟 location 相同,会报错;

2. Insert

插入数据到非分区表

Insert overwrite table table1

Select * from table2

插入数据到分区表,需要指定分区值

insert overwrite table order_joined_extend partition (create_date='2012-09-01', type='ddclick bang')

select addr_id, alliance_id, allot_quantity, city_ship_type_desc, from order_joined_extend1;

一个输入,多个输出

from table2

Insert overwrite table table1 Select *

Insert overwrite table table3 Select *

动态分区

set hive.exec.dynamic.partition=true;

set hive.exec.dynamic.partition.mode=nostrict;

INSERT OVERWRITE TABLE order_joined_extend PARTITION(createdate, type)

SELECT *

FROM order joined extend1 ;

Hive将会以select的最后两列作为动态分区的值,将createdate, type相同的列插入到一个partition中

将query的结果写入文件

写到本地文件

insert overwrite local directory '/home/zhouweiping/directory.dat'
select * from order joined extend limit 10;

```
写到hdfs
insert overwrite directory '/home/zhouweiping/directory.dat'
select * from order_joined_extend limit 10;
```

3. select

一般的 SQL 语句都支持

在使用聚合函数时,select 的列必须是 group by 后面的字段或者只用了聚合函数的;

4. Join

Hive 只支持等值连接(equality joins)、外连接(outer joins)和(left semi join)。Hive 不支持所有非等值的连接,因为非等值连接非常难转化到 map/reduce 任务;hive 也不支持 in 子查询,但是可以用 left semi join 实现 in 操作。另外,Hive 支持多于 2 个表的连接。

有些数据库,例如 MySQL 和 Oracle, 允许在 SELECT 语句的 FROM 子句中列出要连接的表,而在 WHERE 子句中指定连接条件。但是 Hive 并不支持这种语法,所以下面的语句会由于解析出错而导致运行失败。

```
SELECT sales.*, things.*
FROM sales, things
WHERE sales.id = things.id;
```

Hive 只允许在 FROM 子句中出现一个表。要进行连接操作,必须遵循 其他的等值连接跟关系型数据库一样;

JOIN 子句中表的顺序很重要:一般最好将最大的表在最后。

写 LEFT SEMI JOIN 查询时必须遵循一个限制:右表(sales)只能在 ON 子句中出现。例如,我们不能在 SELECT 表达式中引用右表。

并运算 union all

```
INSERT OVERWRITE TABLE actions_users

SELECT u.id, actions.date

FROM (

SELECT av.uid AS uid

FROM action_video av

WHERE av.date = '2008-06-03'

UNION ALL

SELECT ac.uid AS uid

FROM action_comment ac

WHERE ac.date = '2008-06-03'

) actions JOIN users u ON(u.id = actions.uid);
```